

Détection de données Out-of-Distribution (OOD)

par distillation de modèles

Ekaterina Bogush


Encadrement :

Clément Rambour

Machine Learning & Deep Learning for Information Access (MLIA)


ISIR

TEACHER MODEL




STUDENT MODEL

Plan

- 
- 01 — **Détection OOD : le principe**
 - 02 — **Evolution des méthodes de détection OOD**
 - 03 — **Notre approche : la distillation**
 - 04 — **La distillation est-elle une bonne piste?**

Principe de détection OOD


ID = In-(training)-Distribution
OOD = Out-of-(training)-Distribution



Si le classifieur reçoit une image
d'une classe qu'il a jamais vu?


Principe de détection OOD

ID = In-(training)-Distribution
OOD = Out-of-(training)-Distribution




Si le classifieur reçoit une image
d'une classe qu'il a jamais vu?

Attribuer le score OOD




Principe de détection OOD

ID = In-(training)-Distribution
OOD = Out-of-(training)-Distribution



Si le classifieur reçoit une image
d'une classe qu'il a jamais vu?

Attribuer le score OOD



Convention 1

ID

OOD

Score = ID-ness

↑ ID ↓ OOD

Convention 2

OOD

ID


Score = OOD-ness

↑ OOD ↓ ID




**convention 2
permet souvent
d'améliorer les
métriques**


Far-OOD & Near-OOD



CIFAR-10




CIFAR-100




MNIST



Evolution des méthodes de détection OOD





Méthodes basées sur la distillation



Score OOD

**Désaccord entre
teacher-student**

Méthodes basées sur la distillation



Score OOD

Désaccord entre
teacher-student

La distillation est-elle efficace pour détecter les OOD ?

Convention 1

ID

OOD

Score = ID-ness

↑ ID ↓ OOD

Qualité du ranking :
les **ID** ont-ils un score plus élevé
que les **OOD** ?

En gardant 95 % des **ID**, combien d'**OOD**
sont pris pour des **ID** ?

ROC AUC ↑ / FPR@95 ↓

	ID : CIFAR-10		ID : CIFAR-100	
	Near-OOD	Far-OOD	Near-OOD	Far-OOD
Baseline	87.9 / 62.4	91.1 / 57.7	79.2 / 79.4	75.4 / 88.4
Meilleur avec débruitage	86.7 / 57.4 ↓ 1.2 / ↑ 5.0	97.4 / 14.5 ↑ 6.3 / ↑ 43.2	68.4 / 89.6 ↓ 10.8 / ↓ 10.2	97.8 / 10.8 ↑ 22.4 / ↑ 77.6
Meilleur avec distillation	85.9 / 58.1 ↓ 2.0 / ↑ 4.3	94.8 / 24.2 ↑ 3.7 / ↑ 33.5	75.1 / 84.2 ↓ 4.1 / ↓ 4.8	86.9 / 61.0 ↑ 11.5 / ↑ 27.4

La distillation est-elle efficace pour détecter les OOD ?

Convention 1	
ID	OOD

Score = ID-ness
↑ ID ↓ OOD

Qualité du ranking :
les **ID** ont-ils un score plus élevé
que les **OOD** ?

En gardant 95 % des **ID**, combien d'**OOD**
sont pris pour des **ID** ?

ROC AUC ↑ / FPR@95 ↓

	ID : CIFAR-10		ID : CIFAR-100	
	Near-OOD	Far-OOD	Near-OOD	Far-OOD
Baseline	87.9 / 62.4	91.1 / 57.7	79.2 / 79.4	75.4 / 88.4
Meilleur avec débruitage	86.7 / 57.4 ↓ 1.2 / ↑ 5.0	97.4 / 14.5 ↑ 6.3 / ↑ 43.2	68.4 / 89.6 ↓ 10.8 / ↓ 10.2	97.8 / 10.8 ↑ 22.4 / ↑ 77.6
Meilleur avec distillation	85.9 / 58.1 ↓ 2.0 / ↑ 4.3	94.8 / 24.2 ↑ 3.7 / ↑ 33.5	75.1 / 84.2 ↓ 4.1 / ↓ 4.8	86.9 / 61.0 ↑ 11.5 / ↑ 27.4

Super sur Far-OOD,
mais pas sur
Near-OOD

Mieux sur le
Near-OOD, mais loin
des travaux
précédents

**Merci pour votre
attention**

Problème de 2 conventions

Convention 1

ID

OOD

POV : Preserve normal operation

Can I keep the system operating normally on almost all familiar inputs, and under that constraint, how much OOD still slips through?

Convention 2

OOD

ID

POV : Safety-first

If I insist on catching almost all unfamiliar or suspicious inputs, how much does that disrupt normal operation?

		Near-OOD	Far-OOD	
		CIFAR-100	MNIST	SVHN
ResNet-18 MSP	ID+	87.9 / 62.4	91.8 / 55.6	90.4 / 59.8
ResNet-18 MSP	OOD+	87.9 / 43.7 — / ↑ 18.7	91.8 / 23.0 — / ↑ 32.6	90.4 / 26.6 — / ↑ 33.2

Problème de 2 conventions


Convention 1

ID

OOD

POV : Preserve normal operation

Si je détecte 95 % des ID, combien d'OOD sont mal classés ?



Convention 2

OOD

ID

POV : Safety-first

Si je détecte 95 % des OOD, combien d'ID sont mal classés ?

